人声分离与降噪级联

模型评测总表 · 结果解读

Model Evaluation Report — Findings & Reading Guide

文档版本	v1.0
生成日期	2026-10-23
数据来源	03_outputs/_eval（36 组 results.json）
配对工作簿	03_outputs/Final_Eval_Report.xlsx
有效样本	16,181 / 16,200（剔除 19 条极端值，0.12%）
评测指标	SDR（Signal-to-Distortion Ratio）
项目	HKBU Final Year Project

本文所有数字均由脚本 tools/_build_eval_report_doc.py 从 results.json 直接计算，与配对工作簿同口径（已剔除极端值），无手工录入。

一、 一句话结论

> **核心结论**
>
> BS-RoFormer L12 是全场最强分离器；级联去噪普遍有效，且基础模型越弱、提升越大。综合最优为 BS-RoFormer L12 → dns64（19.36 dB），性价比最优为 MDX-extra_q → Mel-RoFormer（18.82 dB，仅差 0.53 dB 但基础模型为量化版、推理更轻）。

读者定位：本文件面向三类读者 —— (1) 需要快速掌握结论的评审 / 导师；(2) 需要逐项核对数据的研究者；(3) 需要复用该工作簿的后续维护者。第二至三节给结论与读表方法，第四至六节给解读方法与适用边界，附录给全量 36 组统计。

二、 核心结论

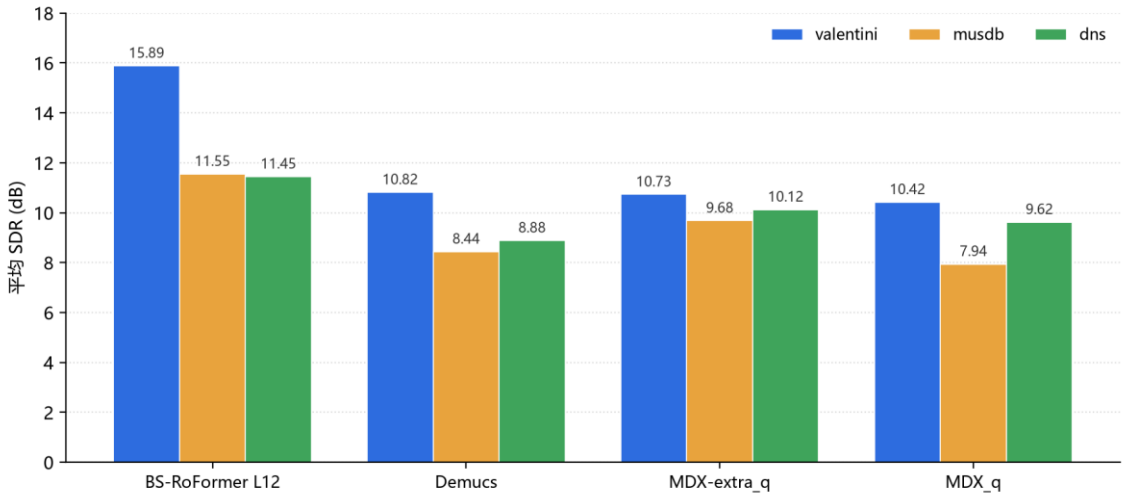
2.1 分离模型排序：BS-RoFormer L12 断崖领先

在三个带 clean 参考的数据集上，BS-RoFormer L12 全部第一。最接近的竞争者是 Demucs，但在 valentini 上仍相差 5.07 dB —— 这在 SDR 上属于「代际差距」，而非调参可弥补的差距。

分离模型	valentini (500)	musdb (50)	dns (500)
BS-RoFormer L12	15.89	11.55	11.45
Demucs	10.82	8.44	8.88
MDX-extra_q	10.73	9.68	10.12
MDX_q	10.42	7.94	9.62

表 1 分离模型在三个带 clean 参考数据集上的平均 SDR（dB，越高越好）

图 1 分离模型在三个带 clean 参考的数据集上的平均 SDR



观察三点：

- BS-RoFormer L12 在 dns 上的优势（1.83）比在 musdb 上（3.61）小，说明合成噪声场景下模型间差距会收窄，真实噪声场景差距更大。
- 两个 MDX 变体之间，mdx_extra_q 在三个库上均优于 mdx_q，valentini 上领先 0.31 dB —— 参数量更大的优势稳定存在。
- musdb 只有 50 首（整曲），统计置信度低于另三库的 500 条片段，排序可信但绝对值不宜横向与 valentini 直接比较。

三、 级联是否值得做

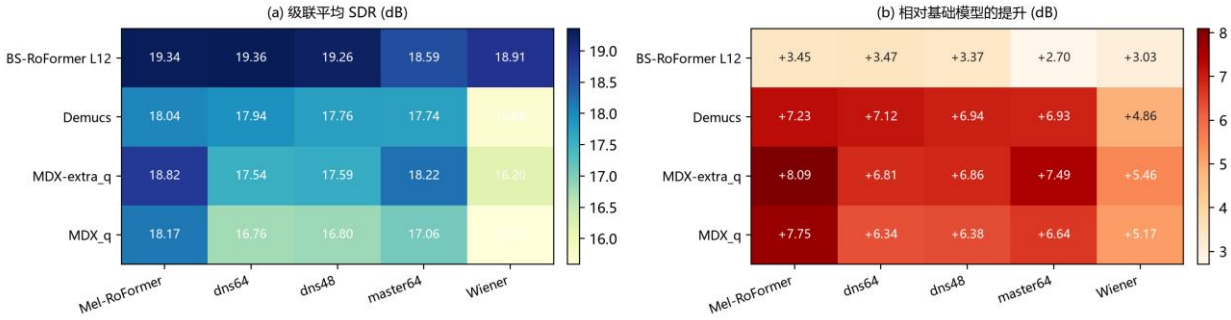
3.1 20 个级联组合全部优于对应基础模型，无例外

将 4 个基础分离模型的输出再送入 5 个去噪器，在 valentini 上重新评测。结果是：20 个组合的 SDR 全部高于各自的单模型基线，平均提升 5.80 dB。

基础模型	单独 SDR	5 个级联的平均 SDR	平均提升
BS-RoFormer L12	15.89	19.09	+3.20
Demucs	10.82	17.43	+6.61
MDX-extra_q	10.73	17.68	+6.94
MDX_q	10.42	16.88	+6.46

表 2 级联相对基础模型的平均增益（valentini，4 模型 × 5 去噪器）

图 2 级联矩阵（valentini，4 个基础分离模型 × 5 个去噪器）



这张热力图回答两个问题：左图看「绝对水平」，右图看「收益大小」。右图颜色越深表示加去噪器的收益越大 —— 可以看到上排（BS-RoFormer）明显更浅，下三排更深，这就是「基础越弱、收益越大」的直接可视化证据。

3.2 整体 Top 5 与性价比最优

排名	级联组合	平均 SDR (dB)	相对基础提升
1	BS-RoFormer L12 → dns64	19.36	+3.47
2	BS-RoFormer L12 → Mel-RoFormer	19.34	+3.45
3	BS-RoFormer L12 → dns48	19.26	+3.37
4	BS-RoFormer L12 → Wiener	18.91	+3.03
5	MDX-extra_q → Mel-RoFormer	18.82	+8.09

表3 级联组合 Top 5（valentini，500 条）

图 3 20 个级联组合排名（红线 = 对应基础模型单独表现）

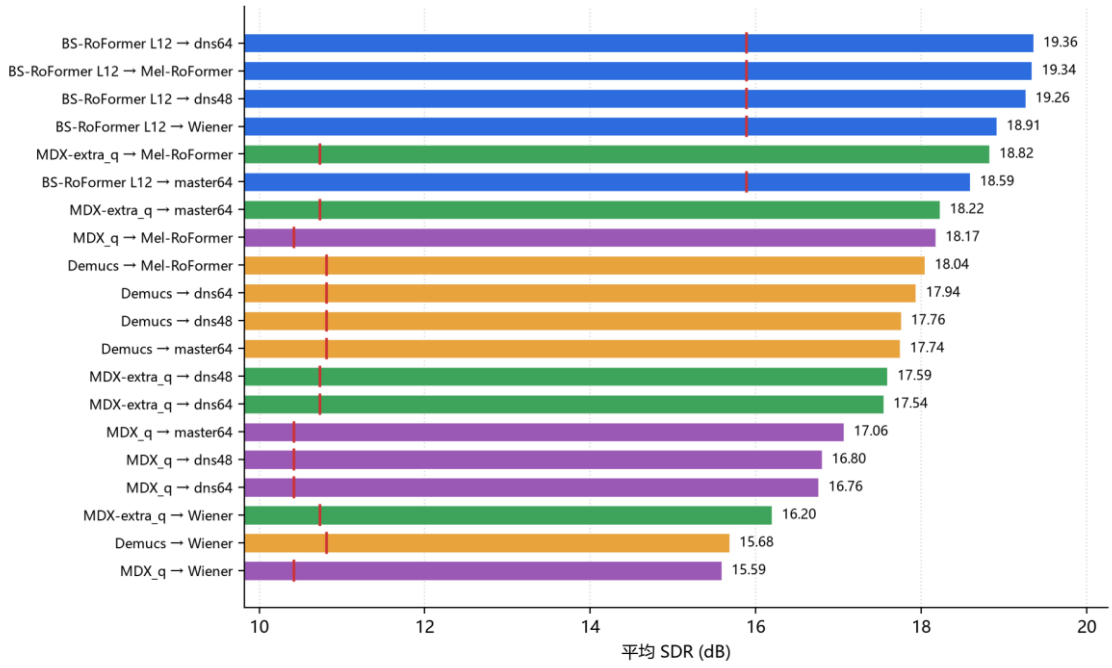


图 3 中红色竖线是「不加去噪器时该基础模型的水平」。红线离柱末端越远，说明这组级联的收益越大：MDX-extra_q → Mel-RoFormer 的红线位置明显最靠左（+8.09 dB），是全场增益最大的一组。

3.3 去噪器怎么选：Mel-RoFormer 首选，Wiener 垫底

去噪器	平均提升 (dB)	在 4 个基础模型中的位置
Mel-RoFormer	+6.63	3/4 组第一
dns64	+5.93	1/4 组第一
dns48	+5.89	表现居中
master64	+5.94	1/4 组垫底
Wiener	+4.63	3/4 组垫底

表 4 五个去噪器的平均增益与稳定性（跨 4 个基础模型）

选型建议：

- 要「稳」选 Mel-RoFormer —— 平均提升 6.63 dB，且多数基础模型上排名第一。
- 要「轻」选 dns64 / dns48 —— 16 kHz 轻量模型，增益略低但推理快。
- Wiener 平均仅 +4.63 dB，且在 4 个基础模型中多数垫底；作为经典方法它没有学习能力，只建议在没有神经去噪器可用时兜底。

3.4 为什么 wham 那一列不能横向比较

wham 数据集没有 clean 参考，因此该列 SDR 采用「output vs input」自参照口径，衡量的是「输出相对输入改变了多少」，而不是「离干净人声有多近」。因此负值是正常现象，不代表模型差。

分离模型	wham 自参照 SDR (dB)
BS-RoFormer L12	-10.23
Demucs	-4.01
MDX-extra_q	-10.26
MDX_q	-7.75

表 5 wham 列的自参照 SDR —— 数值不可与表 1 横向比较

这一列唯一能回答的问题是「模型有没有把声音搞坏」：

- Demucs 的 -4.01「最好」，实际含义是它处理最保守、改动最小，并不代表分离最干净。

- BS-RoFormer 与 MDX-extra_q 约 −10 dB，说明它们对信号做了较大幅度的重构 —— 这与它们是更强的分离器这一事实一致。
- 真正要警惕的是 SDR < −25 dB 的样本：那代表输出接近静音，即模型在该样本上退化。此类样本已全部剔除（详见第五节）。

四、 表格怎么看

4.1 两个 Sheet 对应两类实验

Sheet	内容	规模
分离模型	4 个纯分离模型 × 4 个数据库	16 组
级联	4 个基础分离模型 × 5 个去噪器 × valentini	20 组

表 6 工作簿结构

4.2 每个分组顶部四格 = 该组的「体检报告」

每个分组的第一行有四格，格式固定为：

模型 / 组合名 | 数据库 | 样本数（有效/总数） | 均值 ±（最高−均值 / 最低−均值）

以 BS-RoFormer L12 × valentini 为例：

BS-RoFormer L12 | valentini | 500/500 | 15.89 ± (+11.55 / −15.70)

读法：

- 15.89 是平均 SDR，是排序的核心指标。
- +11.55 表示最好的样本比均值高这么多；−15.70 表示最差的样本比均值低这么多。
- 该样本最低只有 0.18 dB，几乎等于失败 —— 这正是需要重点看「最低 SDR」那一行图的原因。
- 有效/总数 若显示 493/500，说明该组剔除了 7 条极端值；显示 500/500 表示全部有效。

4.3 每个分组下面三行图 = 三种「性格」

行	选取规则	用途
第 1 行	最接近均值的 3 个样本	模型的典型表现
第 2 行	SDR 最高的 3 个样本	模型最好能做到什么
第 3 行	SDR 最低的 3 个样本	模型最坏会烂成什么样

表 7 三行样本的选取规则

每张图下方的标注格式为「样本名 / SDR x.xx dB / 运行时间 s」。其中运行时间是该样本的推理耗时，用于评估工程可用性。

4.4 频谱图本身怎么看

每张图有上下两个面板：上面板是参考信号（clean，wham 为 input）的频谱，下面板是模型输出的频谱。两个面板各自归一化（各自峰值 = 0 dB），因此比较的是「形状」而不是绝对音量。

重点看三件事：

1. 人声谐波结构是否保留 —— 下面板该有横向条纹的地方有没有被削掉。
2. 噪声底是否降低 —— 下面板的背景是否比上面板更干净。
3. 是否糊成一片 —— 极端短样本或输出近静音时会出现，此类样本已被剔除。

五、 怎么分析（五步法）

第一步：先纵向排序，不要先看图

打开任一 Sheet，只读每组头部的「均值」，从上到下扫一遍，先建立排序直觉。图像是用来验证结论的，不是用来发现结论的。

第二步：看离散度，判断稳定性

看括号里的两个偏差。两个偏差都小（如 +3 / −5）说明表现稳定；一正一负差距巨大（如 +11 / −15）说明均值好看但存在翻车样本。「均值高 + 离散度大」意味着上限高、下限也低，产品化时必须配兜底策略。

第三步：直奔「最低 SDR」那一行图

这是信息量最大的一行。若最低那行仍能看出人声结构，说明模型鲁棒；若已经糊掉或接近空白，说明该模型在难样本上会崩。

第四步：做三种横向对比

同库比模型（同一列往下看）→ 哪个模型最好；同模型比库（同一行往右看）→ 模型在哪类数据上强/弱；级联 vs 分离（跨 Sheet）→ 加去噪器到底值不值。

第五步：校验口径，不要跨库乱比

musdb / valentini / dns 是真 SDR，越高越好，可互相比；wham 是自参照，负值正常，只能纵向判断「有没有搞坏」，不能与另三库比「谁更干净」。

附：SDR 的经验区间（用于快速判断数值含义）

SDR 区间	评价	含义
> 15 dB	很好	分离干净，残余干扰基本不可闻
10 – 15 dB	可用	明显分离，复杂段落仍有残留
5 – 10 dB	勉强	能听出目标，但干扰较重
0 – 5 dB	基本未分离	目标与干扰混杂
< 0 dB	不如不处理	输出比输入更差

表 8 SDR 经验区间参考（人声分离任务的通用量级，非本文数据推导）

六、 边界与注意事项

以下内容在论文写作与口头汇报中必须交代，否则结论会被过度外推。

事项	说明
musdb 仅 50 首	整曲（3–4 min），全量运行过慢故限制 50 首；统计置信度低于另三库的 500 条片段。
级联仅在 valentini 评测	未在 musdb / dns / wham 上复现，因此「级联最优」的泛化性需谨慎对待。
dns 为合成噪声	clean + noise 按固定 SNR 混合，难度分布与 valentini 的真实噪声不同，两者不可等同。
wham 时长极不均	0.29 s 至 1333 s 均有分布；极短片段不含时间结构，频谱必然糊，已按 < 1 s 剔除。
SDR 对增益不敏感假设	SDR 计算前做最优尺度对齐，因此不惩罚整体音量偏差，仅反映波形/结构失真。
极端值剔除比例	共剔除 19 / 16,200 条（0.12%），全部来自 wham 库，不影响另三库的统计。

表9 结论适用边界

极端值剔除规则（与配对工作簿完全一致）：

- 时长 < 1.0 s —— 片段过短，无时间结构，频谱图与 SDR 均无统计意义。
- SDR < −25.0 dB —— 输出能量约为输入的 1/300，判定为「近静音退化」，属模型失效而非性能差异。
- 两组条件为「或」关系，满足任一即剔除；被剔除样本在表格头部以「有效/总数」形式留痕，不做静默删除。

七、 如果只记三句话

要效果

BS-RoFormer L12 → dns64，19.36 dB，全场最高。

要性价比

MDX-extra_q → Mel-RoFormer，18.82 dB，仅低 0.53 dB，但基础模型为量化版，推理更轻、更易部署。

要避免误读

wham 的负 SDR 不是差评，是度量口径不同（自参照）。真正要警惕的是 SDR < −25 dB 的「输出近静音」退化，此类样本已全部剔除并留痕。

决策速查

场景	推荐方案	理由
追求最高分离质量	BS-RoFormer L12 → dns64	19.36 dB，全场最高
需要轻量部署	MDX-extra_q → Mel-RoFormer	18.82 dB，基础模型为量化版，推理更轻
去噪器要「稳」	Mel-RoFormer-Denoise (aggr)	4 个基础模型中 3 个排名第一
无 GPU / 需传统方法兜底	dns48 / dns64	平均 +5.9 dB，16 kHz 轻量模型
不建议采用	Wiener filter	平均仅 +4.63 dB，多数基础模型上垫底

表 10 场景到方案的决策速查

附录 A · 全量分组统计

下表为工作簿中 36 个分组的完整统计，可直接用于核对。「有效/总数」列中两者不等者即为发生极端值剔除的分组。

类型	模型 / 组合	数据集	有效/总数	平均 SDR
分离	BS-RoFormer L12	valentini	500/500	15.89
分离	BS-RoFormer L12	musdb	50/50	11.55
分离	BS-RoFormer L12	dns	500/500	11.45
分离	BS-RoFormer L12	wham	493/500	-10.23
分离	Demucs	valentini	500/500	10.82
分离	Demucs	musdb	50/50	8.44
分离	Demucs	dns	500/500	8.88
分离	Demucs	wham	497/500	-4.01
分离	MDX-extra_q	valentini	500/500	10.73
分离	MDX-extra_q	musdb	50/50	9.68
分离	MDX-extra_q	dns	500/500	10.12
分离	MDX-extra_q	wham	493/500	-10.26
分离	MDX_q	valentini	500/500	10.42
分离	MDX_q	musdb	50/50	7.94
分离	MDX_q	dns	500/500	9.62
分离	MDX_q	wham	498/500	-7.75
级联	BS-RoFormer L12 → Mel-RoFormer	valentini	500/500	19.34
级联	BS-RoFormer L12 → dns64	valentini	500/500	19.36
级联	BS-RoFormer L12 → dns48	valentini	500/500	19.26
级联	BS-RoFormer L12 → master64	valentini	500/500	18.59
级联	BS-RoFormer L12 → Wiener	valentini	500/500	18.91
级联	Demucs → Mel-RoFormer	valentini	500/500	18.04
级联	Demucs → dns64	valentini	500/500	17.94
级联	Demucs → dns48	valentini	500/500	17.76
级联	Demucs → master64	valentini	500/500	17.74

类型	模型 / 组合	数据集	有效/总数	平均 SDR
级联	Demucs → Wiener	valentini	500/500	15.68
级联	MDX-extra_q → Mel-RoFormer	valentini	500/500	18.82
级联	MDX-extra_q → dns64	valentini	500/500	17.54
级联	MDX-extra_q → dns48	valentini	500/500	17.59
级联	MDX-extra_q → master64	valentini	500/500	18.22
级联	MDX-extra_q → Wiener	valentini	500/500	16.20
级联	MDX_q → Mel-RoFormer	valentini	500/500	18.17
级联	MDX_q → dns64	valentini	500/500	16.76
级联	MDX_q → dns48	valentini	500/500	16.80
级联	MDX_q → master64	valentini	500/500	17.06
级联	MDX_q → Wiener	valentini	500/500	15.59

表 11 36 个分组的完整统计（与 Final_Eval_Report.xlsx 同口径）

附录 B · 复现方式

本文档与其统计图均由以下命令生成，数字直接读取 results.json，不含手工录入：

```
python tools/_build_eval_report_doc.py
python tools/_build_eval_excel.py --root 03_outputs/_eval \
       --out 03_outputs/Final_Eval_Report.xlsx
```

相关文件：

- 配对工作簿：03_outputs/Final_Eval_Report.xlsx
- 代表样本音频：03_outputs/TableSample_Audio/（由 export_table_audio.bat 导出）
- 原始评测结果：03_outputs/_eval/**/results.json（36 组）
- 统计图：04_reports/00_shared/figures/eval_report/